G^2VLM：统一三维重建与空间推理

历史论文按新提示词重制版 · CVPR 2026 · 2026-10-07

对应离线阅读包：解压ZIP后双击 index.html。本PDF包含完整13项学习简报，并重点展开创新点、核心算法、数学公式和固定commit源码；完整原文及逐节译文在ZIP中。

1 基本信息与分类标签

论文：G^2VLM: Geometry Grounded Vision Language Model with Unified 3D Reconstruction and Spatial Reasoning。作者 Wenbo Hu、Jingli Lin、Yilin Long 等；机构包括 Shanghai AI Lab、UCLA、SJTU、FDU、ZJU、USTC、HKU、CUHK。首次提交 2025-11-26，选定 v2 为 2025-11-27；官方仓库于 2026-02-20 宣布被 CVPR 2026 接收。

资源：论文 · 项目页 · 固定源码 · 2B 权重。G^2VLM-SR 权重当前仍标为待发布。

标签：VLM、3D 重建、深度估计、点图、相机位姿、空间推理、Mixture-of-Transformers、多视图视觉。

一句话问题：如何让 VLM 不靠外接几何工具，就能从多图恢复三维结构，并让连续几何特征参与语言化空间推理？

2 推荐理由

你已有 VGGT + Depth Pro + YOLO 的“检测—深度—重建”流水线，也做过 Qwen2.5-VL LoRA。G^2VLM 补足的是两条线之间的接口：不是把点云转成文本再喂 VLM，而是把 DINO 几何词元与 Qwen 语义词元放入每层共享注意力。它能具体回答：几何监督怎样进入大模型、点图与位姿怎样从 LLM 隐状态解码、冻结哪个专家可保住重建能力、何时应让语言 CE 更新几何表示。

3 真正创新点：已有方法 vs 本文

维度	专用几何/外接工具	普通 VLM	G^2VLM
表示	点图/位姿，缺语言	语义词元，度量几何弱	DINO 几何专家 + Qwen 语义专家；共享注意力
融合	重建结果在模型外	单视觉塔 + LLM	每层 MoT 内交互，几何词元参与推理
几何头	VGGT 重型 DPT	无稠密三维头	五层帧内 Transformer + MLP/pixel shuffle
监督	纯几何 loss	语言 CE	Freeze+CE、CE+CE、VG+CE 三种梯度路由
证据	几何强、问答弱	Qwen2-VL 微调 SPAR 48.93	G^2VLM-SR 54.87，提升 5.94 个百分点；Sintel 0.297

创新 1：双专家不是串联工具

旧方法先重建再把结果交给 VLM，误差在模块边界固化。本文让两个同深度专家在层内共享注意力，语义与几何双向影响。双编码器、全局注意力消融支持此设计。DINOv2、Qwen2-VL、MoT 和 π^3 头是沿用模块；真正新意是统一和训练路线。

创新 2：从统一隐藏状态解码三维

DINO 特征投影到 Qwen 隐藏空间，再由几何专家输出局部点图、位姿和训练期全局点图。因此同一隐藏序列同时服务重建与语言。论文只证明几何“可比”，未证明全面领先。

创新 3：把联合训练权衡显式化

冻结几何保持重建并用海量语言/视频扩展；CE+CE 使几何面向问答；VG+CE 最强但需同步三维标注。贡献不是新 loss，而是把梯度路径、任务收益与数据代价讲清。

4 方法流程

- 图像分别进入 DINOv2 和 Qwen2 视觉编码器。
- DINO 词元经 dino2llm 投影，与语义/文本词元组成 packed sequence，并构造位置与 block mask。

- 28 层双专家读取共享多模态上下文，同时保留各自参数路径。
- 几何隐藏状态经点图、相机、全局点图解码器；语言隐藏状态经 LM head。
- 训练策略决定几何分支冻结、接 CE，还是接 CE+L_{VG}。
- 推理时 model.recon 输出点图/位姿并保存 PLY，聊天入口生成空间答案。

5 算法一：双专家共享注意力

输入输出与形状

B 为批量，N 视图，H/W 高宽，P 每图 patch 数，D 隐藏维。DINO 输出约 [B,N,P,D_{dino}]，投影为 [B,N,P,D]；Qwen 图像词元 [B,Q,D]，文本 [B,L,D]。打包长度 S≈NP+Q+L，源码实际使用 [ΣS,D] 与 cu_seqlens，而非简单密集 [B,S,D]。

预处理、mask、训练与推理

两视觉塔分别 resize/normalize。prepare_dino_images_pi3 组织 DINO 图像及位置，prepare_vit_images 组织 Qwen 图像，slice_expand_and_flatten 展平片段。block mask 隔离不同样本，同一样本多视图与文本做全局注意力。几何预训练只让几何路径收梯度；联合阶段依配置冻结或更新。生成推理使用 KV cache，重建则一次解码 patch。

小例子

B=1、N=2、每图 4 个 DINO patch、Qwen 6 个视觉词元、文本 3 个词元，则 S=17，注意力矩阵 17×17；答案词元可直接关注两视图的 8 个几何词元。

```
自行编写的示意伪代码（不是作者源码）
g = project(DINO(images)) # [B,N,P,D]
s = QwenVision(images) # [B,Q,D]
x, mask = pack(g, s, text_tokens)
for geo_block, sem_block in layers:
context = shared_attention(x, mask)
g = geo_block(g, context)
s = sem_block(s, context)
return geometry_heads(g), lm_head(s)
```

源码：G2VLM.__init__ 119–239；forward 248–552；DINO 词元准备与 cache 更新 864–1133。

> 论文给概念性双专家图；代码建立在 Bagel/Qwen packed inference 上。复现时必须跟踪 cu_seqlens、position_ids 与 block mask，不能按普通 [B,S,D] Transformer 猜。

6 算法二：点图—相机联合解码

输入输出与前向

几何隐藏状态恢复到 B、N 和 patch 网格。点头输出 [B,N,H,W,3]：前两通道为射线坐标 xy，第三通道为深度 z，组合成 [xy · z,z]。相机头输出 [B,N,4,4]。齐次局部点经矩阵乘法得到世界点 [B,N,H,W,3]。

$$X^{world}_{b,n,h,w,i}=\Sigma_j T_{b,n,i,j}[X^{local},1]_{b,n,h,w,j}$$

训练时局部点、位姿和全局点都可监督；全局点头只稳定训练。相机旋转的 9D 表示经 SVD 正交化。例：xy=[0.5,0]、z=2 得局部点 [1,0,2]；相机沿 x 平移 3 后世界点为 [4,0,2]。

```
自行编写的示意伪代码（不是作者源码）
raw = point_head(point_decoder(hidden))
xy, z = raw[..., :2], raw[..., 2:3]
local = concat([xy * z, z], -1)
T = camera_head(camera_decoder(hidden)).reshape(B,N,4,4)
world = einsum('bnij,bnhwj->bnhwi', T, homogenize(local))[...,:3]
```

源码：训练前向 448–521；reconstruct 1237–1325；推理入口 27–47。

7 算法三：两阶段训练与梯度路由

阶段	几何专家	语义专家	损失
几何预训练	更新	冻结	L_{VG}
仅 CE（主模型）	冻结	更新	L_{CE}

阶段	几何专家	语义专家	损失
CE+CE（SR）	更新	更新	L_{CE}
VG+CE	更新	更新	$L_{CE}+L_{VG}$

visual_recon、pretrain_train_recon、joint_train_recon、ce_loss_dino
控制分支和梯度。冻结时几何特征仍参与前向，只是不更新参数。

源码：配置 79–113；冻结逻辑 210–239；损失返回 527–552；训练入口 pretrain.sh / joint_train.sh。

8 数学公式详解

8.1 尺度不变点图损失（式 3）

s* 在整组视图求共同尺度，再计算深度归一 L1。x⊠、x∈R^3，z∈R；除数 3NHW 对坐标和像素平均。L1 比 L2 抗错误三维标注，1/z 近似相对误差。例：真实 [0,0,2]、预测 [0,0,1]，s*=2 时误差 0；若预测深度 1.8 且 s=1，加权误差 |1.8−2|/2=0.1。梯度推动方向和深度，但不惩罚公共尺度自由度。

8.2 SO(3) 旋转测地损失（式 5）

R⊠R⊠ 为相对旋转，(Tr−1)/2=cosθ，arccos 得角误差。输入是两个 3×3 矩阵，输出标量弧度。相差 60° 时迹为 2，损失 arccos(0.5)=π/3。它比矩阵元素 MSE 符合旋转流形，但接近 ±1 需数值 clamp。

8.3 Huber 平移（式 6）

先用 s* 对齐预测平移，再用 Huber：小误差二次、利于精调，大误差线性、抑制异常值。λ_{trans}=200 反映平移与旋转量纲不同。δ=1 时，误差 0.2 得 0.02；误差 3 得 2.5。

8.4 法向角损失（式 7）

单位法向点积为 cosθ，arccos 直接惩罚表面方向；点积 0.5 对应 60°。它补充点位置损失，因为位置接近的点仍可能构成不同倾斜面。法向由邻域点估计，梯度会联动相邻像素。

8.5 语言交叉熵

$$L_{CE}=-(1/T)\Sigma_t \log p(y_t|y_{<t},I_{1:N})$$

logits 为 [M,V]，M 是 ce_loss_indexes 选中的回答位置，V 为词表。源码在 527–531 行只对选中位置过 LM head，避免监督图像/提示词元。CE+CE 时梯度经共享注意力回到几何专家。

损失源码：Pi3Loss；g2vlm.py:521 调用。论文采用 MoGe/π^3 的尺度与法向实现，公开代码沿用其组件。

9 实验与证据

- Sintel AbsRel 0.297，优于 VGGT 0.335、弱于 π^3 0.277；NYU AbsRel 0.062。
- Co3Dv2 AUC@30 74.81，低于 VGGT 88.59，不能概括成全面 SOTA。
- SPAR 54.87；相对同数据微调 Qwen2-VL-2B 的 48.93，净增 5.94 个百分点。
- 帧内/混合/全局注意力分别 52.34/53.64/54.87，与几何性能排序一致。
- 以上为论文报告；本次未实际运行模型验证。

10 局限与前置知识

作者明确：VG+CE 要求三维标注；内部合成数据不可完整公开；SR 权重尚待发布。分析推断：双 28 层专家与双视觉塔较重，不宜直接车端部署；无显式时序状态，动态驾驶场景可能跨帧不一致；将大于 10 的损失置零可能舍弃困难样本。

前置知识：（1）点图：每像素三维坐标；（2）SE(3)：旋转和平移的刚体变换；（3）尺度不确定性：单目只恢复到公共尺度；（4）packed attention：以 cu_seqlens 在扁平张量隔离样本；（5）梯度冻结：参与前向不等于参数更新。

11 50 分钟学习路线

- 0–8 分钟：看图 1/2，口述双专家数据流。
- 8–20 分钟：精读 3.1，画出 DINO/Qwen token 形状。
- 20–32 分钟：手算式 (3)、(5)、(6)。
- 32–43 分钟：读 g2vlm.py:448–521，追踪 local_points→camera_poses→points。
- 43–50 分钟：比较 SPAR 48.93→54.87 与几何表，回答统一模型换来什么、牺牲什么。

必须看懂：图 2 与式 (3)。思考题：把 Depth Pro 相对深度作为辅助监督时，怎样避免其尺度与 s^* 冲突？

12 代码学习与最小运行

- modeling/g2vlm/g2vlm.py：119–239 构造，248–552 训练前向，1237–1325 重建。
- modeling/pi3/models/pi3_loss.py：检查点、相机、法向的掩码、尺度和 clamp。
- inference_recon.py：最小入口，确认图像、model.recon 与 PLY。

官方路线：Python 3.10、PyTorch 2.5.1/CUDA 12.1，安装 requirements，下载 HF 权重，运行 python inference_recon.py --image_folder ...。论文未给单次推理显存；建议先用 24GB GPU、2–4 张缩放图测试，这是估算。完整训练需 32/64×A800，不应冒充推理要求。

13 面试题与迁移实验

问题 1

为什么双编码器？DINO 保留低层几何和对应关系，Qwen 视觉塔提供语义与动态分辨率；共享注意力让二者互补，代价是算力与对齐复杂度。

问题 2

Freeze+CE、CE+CE、VG+CE 如何选？只有问答数据且要保几何时冻结；追求推理且可容忍几何漂移选 CE+CE；有同步三维标注且要两类能力共同提高选 VG+CE。

迁移到 VGGT / Depth Pro / YOLO

改动：保留 YOLO 检测，增加 cross-attention adapter，把 G^2VLM 几何 token 汇聚到检测框；用 VGGT 点图作教师、Depth Pro 深度梯度作辅助。收益：目标级三维位置更稳，问答不依赖手工点云转文本。假设：动态车景下 token 仍跨视图一致。最小对照：200 组多摄像头帧比较 A YOLO+Depth 数值提示、B VGGT 点云文本、C 几何 token adapter；报告 AbsRel、3D 中心误差、问答准确率和延迟。

迁移到 Qwen2.5-VL / VLA Agent

将语义专家替换为 Qwen2.5-VL，第一阶段只训 DINO 投影和几何头，第二阶段 LoRA 更新语义专家并冻结几何；再让 action head 读取几何 token。最小实验在 LIBERO 选 5 个遮挡任务，对比纯 LoRA 与加冻结几何 token，报告成功率、碰撞率和辅助空间问答。若几何好但动作不升，瓶颈在时间建模/控制头。