WAM-Flow：并行粗到细自动驾驶规划

历史论文按新提示词重制版 · CVPR 2026 · 2026-10-12

对应离线ZIP：解压后双击
index.html。本PDF包含完整13项简报，并重点展开创新点、算法、公式和固定commit源码；完整原文与逐节译文在ZIP中。

1. 基本信息

标题：WAM-Flow: Parallel Coarse-to-Fine Motion Planning via Discrete Flow Matching for Autonomous Driving

作者/机构：Yifang Xu、Jiahao Cui、Feipeng Cai 等；复旦大学、引望智能。会议：CVPR 2026。版本：arXiv:2512.06112v2（2025-12-11），18 页。

论文 · 官方代码（固定 commit） · 权重与数据

证据边界：结果均为论文报告；实现结论来自固定 commit 747dad929a419e11c7fb2fcbd57fec90e9e31a55 的源码静态分析。未下载权重、未运行 NAVSIM、未声称复现。官方仓库公开 SFT、推理和评测，RL 代码仍标为待发布。

2. 分类标签

自动驾驶 · VLA · 端到端规划 · 离散流匹配 · 数值 tokenization · GRPO · 并行解码 · 闭环评测。

3. 个性化推荐理由

它把你的自动驾驶视觉、Qwen2.5-VL 微调与 GRPO 经验接成一条完整链：视觉不再只输出检测/深度，而是与导航、自车状态共同产生未来 4 秒轨迹；动作仍是 token，能复用 VLM SFT；闭环 GRPO 又直接对应你的强化学习经验。它补足的关键知识是：如何让 VLM 用并行生成而非逐 token 自回归完成高精度几何控制。

4. 一句话问题定义

给定前视图、导航命令和自车运动状态，如何并行得到 8 个未来路点，让简单场景只算 1 步、复杂场景多算几步，并用闭环奖励校正安全、进度和舒适性？

5. 真正创新点：已有方法 vs 本文

环节	旧方法/瓶颈	本文改动	为何有效	证据
动作生成	AR 顺序生成坐标，误差累积、延迟固定。	轨迹写成 D 维离散状态，以 CTMC/DFM 并行更新。	一次前向细化所有路点，步数成为算力旋钮。	1步 89.1/0.09s；5步 90.3/0.48s。
数值表示	文本 embedding 不保证相近数值相近，CE 不含米制几何。	20,001 数值 token + 三元组度量排序 + 几何 Gibbs 路径。	噪声/转移有物理意义，可由粗到细修正。	专用 tokenizer +4.9点；度量对齐再 +2.3点。
领域迁移	通用 Janus 缺少驾驶感知与规划先验。	先做 6.5M 道路/通用 VQA，再做 nuPlan SFT。	先补道路语义与因果知识，降低从零训练成本。	预训练约 +3.3 PDMS。
闭环对齐	监督 CE 不直接惩罚碰撞、越界、低进度。	并行采样轨迹组，用 NC×DAC 门控的复合奖励做 GRPO。	同场景相对比较，直接优化闭环指标并以 KL 防漂移。	86.7→90.3 PDMS。

沿用而非创新：Janus-1.5B、SigLIP、xFormers 全注意力、GRPO/PPO clip、NAVSIM 指标和通用 CTMC 理论。新意是将其组织为驾驶 VLA 的度量动作词表、几何路径、AR→DFM 课程和模拟器奖励。

6. 方法流程与张量总览

- 图像保持宽高比缩放并填充到 384×384，形状 [B,Nimg,3,384,384]；SigLIP 每图产生 576 个视觉 token，经 MLP 对齐至 2048 维。
- 导航和自车状态写入 prompt；连续量用 20,001 个数值 token。8×(x,y) 对应至少 16 个动作标量。
- SFT 从几何 Gibbs 路径采样 x_t，只扰动动作区；非因果网络同时预测全部 x_1。
- 推理从随机动作 token 开始，用 n 次 CTMC Euler 更新并行细化，解码为 8 路点。
- GRPO（论文描述，公开实现缺失）并行采样 G 条轨迹，NAVSIM 评分后更新策略。

B=batch，T=动作 token 数，K=词表大小（102,400+20,001），d=embedding 维度，D=离散坐标数，G=候选组大小，n=推理步数。

7. 核心算法一：度量对齐数值 tokenizer 与几何路径

问题与衔接

普通词表让“3.00→3.01”和“3.00→30.00”的类别损失近似相同。本文先使 embedding 距离顺序与数值差一致，再用距离定义噪声路径，贯通输入自车数值、输出路点与 DFM。

输入输出与 shape

V∈R^20001，范围 [-100,100]，步长 0.01；embedding W∈R^{K×d}；目标 id x1:[B,T]；z:[B,T,d]；到所有 token 的距离/概率 [B,T,K]。

预处理与前向

train.py:206–215 生成 20,001 个两位小数 token。init_numeric_and_special_tokens 用数字与小数点 embedding 均值加小噪声初始化。MixtureDiscreteSoftmaxProbPath 归一化 embedding、计算到全词表距离、乘 -β_t 后 softmax 并采样 x_t。

训练、冻结与梯度

论文阶段1冻结 VLA 骨干，更新数值 embedding 与 LM head，目标 LCE+Lnum。公开 train.py 主路径以 CE 为主，并在 132–150 行可选加入 argmax 数值的 MSE。差异：论文的三元组 Lnum 未出现在公开主训练文件中，不能声称式(5)已完整开源。

推理

β_t=3(t/(1-t))^0.9 随 t 增大，分布从近乎均匀逐步集中到目标邻域。

小例子

目标 2.00，候选 1.99/2.10/8.00，理想距离 0.01/0.10/6.00。β=1 时尚有探索；β=10 时概率集中在邻近数值，形成粗到细。

自行编写的示意伪代码（非作者原代码）

```
z = normalize(embed(target_id)) # [B,T,d]
dist = distance_to_vocab(z, E) # [B,T,K]
beta = 3 * (t / (1-t)) ** 0.9
p_xt = softmax(-beta * dist, dim=-1)
x_t = categorical(p_xt)
```

源码与复现注意

核心：metric/get_prob_distribution/sample。源码 L145–147 对已归一化 embedding 的欧氏平方再平方，近似四次方距离，与论文 d=||z_i-z_j||_2 记法不完全一致，必须核对。

8. 核心算法二：并行 DFM 训练与 CTMC Euler 推理

问题与衔接

把因果“下一个 token”改为全序列 x1 预测。训练只给动作位置加几何噪声；推理以 CTMC jump 逐步接近目标。

shape

x_t:[B,L]，text_token_mask:[B,L]；网络 txt_logits:[B,L,K]；mask 后 [M,K]。每步目标 [B,T]，转移率 u:[B,T,K]，jump mask:[B,T]。

预处理、序列和 mask

图像缩放/填充至384并归一化到[-1,1]；数据集展开 576 视觉位置，只标记最后 Assistant 段为动作区。training_step以 x_t*mask+x1*(1-mask) 保持条件 token 干净。

训练与梯度

s1 令 x_t=x1；s2 从几何路径采噪声。只在动作 mask 上算 CE。全注意力改写移除因果 mask，用 xFormers block diagonal mask 隔离样本。梯度经 LM head、Transformer 和阶段配置允许的视觉/embedding 参数回传。

推理

infer.py给动作区填均匀随机 token，以 step_size=1/n 调 solver。网络 use_cache=False；每步所有 token 可能改变，不能复用 AR KV cache。solver 503–548计算距离差、β导数、转移率与 jump 概率。

数值例子

B=1、T=4、K=5、n=2。初始 [4,0,2,1]，后验目标 [3,1,2,2]；若 λ=[2,.2,0,3]、h=.5，则 jump 概率约 [.632,.095,0,.777]。位置1/4较可能变化，位置3保持；下一步重估全序列。

自行编写伪代码（非作者原代码）

```
x = random_tokens(B,T,K)
for k in range(n):
posterior = model(context_with(x)) # [B,T,K]
target = categorical(posterior)
u = metric_rate(x, target, t=k/n)
jump = rand(B,T) < 1-exp(-(1/n)*u.sum(-1))
x[jump] = categorical(u[jump])
return decode(x)
```

论文—代码差异

- 论文写 zero-padding，数据代码实际用 RGB=(127,127,127) 填充。
- attention_mask 全 True，padding 行为需结合 block mask 检查。
- 最后通过字符串按逗号解析 8 对浮点数，不是连续回归 head。
- 1步是一次全序列后验预测，并非只输出一个 token。

9. 核心算法三：模拟器引导 GRPO

问题、shape 与衔接

监督轨迹接近不等于闭环安全。同场景并行生成 G 条 τ:[B,G,8,2]，模拟器返回 R:[B,G]，组内优势 A:[B,G]，动作 log-prob/ratio:[B,G,T]，最终为标量 loss。

奖励与训练

NC×DAC 是安全门，EP/TTC/C 按5:5:2加权。优势为组内去均值；正优势提升概率，负优势降低。PPO式 clip 限制 ratio，KL 锚定 SFT 参考。梯度不穿过模拟器，只经新策略 log-prob/KL。

推理差异

部署仍是 n 步 DFM；无需模拟器、旧策略或候选组。G 是训练超参数。

小例子

G=3，R=[.9,.6,.3]，A=[.3,0,-.3]。若 ratio=1.3、ε=.2，正优势取 min(1.3×.3,1.2×.3)=.36。

自行编写伪代码（非作者原代码）

```
traj, old_logp = old_policy.sample_group(scene,G)
R = navsim(scene,traj)
A = R - mean(R, group)
ratio = exp(policy.logp(traj)-old_logp)
loss = -(min(ratio*A, clip(ratio,1-eps,1+eps)*A)
- beta*kl(policy, reference)).mean()
```

源码映射

未找到对应公开 RL 代码。已检查根目录、train.py、flow_matching/、fudoki/、scripts/；README 发布表仍将 RL training 标为 TODO。上述内容来自论文式(9)(10)，不是作者 RL 源码复述。

10. 数学公式逐式详解

式(5)：三元组数值几何

$$L_{num}=E[\max(0,d_{ij}-d_{ik}+\alpha)]$$

$z\in R^d$ 为归一化 embedding。若 $d_{ij}=.4$、$d_{ik}=.9$、$\alpha=.2$，loss=0；若 $d_{ik}=.5$，loss=.1，梯度拉近近邻或推远远邻。公开主训练代码未找到该 triplet 实现。

式(6)(7)：Gibbs 路径与 CTMC 速率

$$p_t(x|x_1)=\mathrm{softmax}(-\beta_t d(x,x_1));\ u_t(x,z|x_1)=p_t(x|x_1)\,\beta_t'\,[d(z,x_1)-d(x,x_1)]_+$$

softmax 沿 K 个候选 token；β 小时分布平，β 大时集中。正部只允许向更接近目标的候选跳转。当前距离4、候选距离[1,3,5]时，改进量[3,1,−1]→[3,1,0]。源码对应 概率与速率。

式(8)：x1 后验交叉熵

$$L_{CE}=E[-\Sigma_i \log p_{\theta,i1}|t(x_{1i}|x)]$$

每位置输出 K 类概率。目标概率 .2→.5 时，单 token 损失 1.609→.693。CE 与离散采样一致，几何结构由式(5)(6)补足。源码：train.py:108–153。

式(9)：闭环奖励

$$R=(NC\times DAC)\times(5EP+5TTC+2C)/12$$

NC=DAC=1、EP=.8、TTC=1、C=.9 时，R=(4+5+1.8)/12=.90；若 NC=0，奖励为0。乘法更严格地体现安全优先，但会增加稀疏性。

式(10)：GRPO clip + KL

ratio 衡量新旧策略概率变化；A 是组内相对优劣；clip 限制更新；KL 防止能力漂移。A>0 时 ratio 超过1+ε不再增加收益；A<0时 ratio 过低也被截断。论文未公开 RL 源码。

式(11)(12)：评测

PDMS/EPDMS 都先乘安全/合规门，再加权性能项。论文式(12)文字列出 HC，但公式括号没有 HC；此处照原文，实际以官方 NAVSIM-v2 为准。

11. 实验与证据

- 论文报告：NAVSIM-v1 90.3 PDMS；NAVSIM-v2 84.7 EPDMS；nuScenes UniAD 指标平均碰撞率0.23%。
- 组件链：76.2→81.1→83.4→86.7→90.3，对应普通词表、专用数值、度量对齐、VQA、GRPO。
- 速度—精度：1步89.1/0.09s；3步90.0/0.29s；5步90.3/0.48s；10步90.2/0.94s。
- 边界：并非所有子指标第一；NAVSIM-v2 EC=73.9，NAVSIM-v1 EP=82.3。

12. 局限与适用范围

作者报告：主要在仿真评估；sim-to-real 奖励需重设计；基准不覆盖全部长尾。源码静态分析推断：单前视图限制侧后方交互；[B,T,K] 在 K≈122k 时显存昂贵；字符串路点解析对格式敏感；缺 RL 代码使完整重训无法公开核验。

13. 前置知识

- CTMC：连续时间跳转率描述离散状态演化。
- 流匹配：学习从简单分布到数据分布的概率路径。
- 数值 tokenization：量化范围、分辨率与 embedding 几何决定米制误差。
- GRPO/PPO：组内优势、ratio、clip 与 KL 控制更新稳定性。
- 闭环指标：动作改变后续场景，PDMS 不能由开环 L2 替代。

14. 45 分钟学习路线

- 0–8分：看图2、表6，明确输入、8路点和1/5步差异。
- 8–20分：精读式(6)(7)，解释β、距离差正部与 jump 概率。
- 20–30分：读 train.py:76–153 和 solver:503–548，画 [B,T,K] 张量流。
- 30–38分：对照表5，分清 tokenizer、度量、VQA、GRPO 的增益。
- 38–45分：思考分层粗细 token 能否保留0.01m精度并降低 softmax 成本。

必须看懂：图2与式(7)。

15. 代码学习任务与最小运行路线

- train.py::training_step：噪声、mask、CE/L2、梯度入口。
- MixtureDiscreteSoftmaxProbPath：metric、β与采样。
- infer.py::main和solver.sample：推理。

路线：按 README 安装 Python3.9，下载 HF checkpoint/processor/embedding，运行 torchrun infer.py，discrete_fm_steps=5。官方未给单次推理显存；1.5B FP32
权重理论下限约6GB，实际需更多，这是估算。完整训练是论文报告的32张 Ascend 910B。

16. 面试价值

问1：为什么“一步”能输出完整轨迹?
答：非因果全注意力使动作位置同时预测 x1；一步是一次全序列 DFM 更新，不是一个 token。

问2：普通数值 token、度量对齐 token 与连续回归如何取舍?
答：普通 token 可复用 LM
但无物理邻域；度量对齐保留统一离散生成和多峰表达；连续回归直接但难统一语言动作空间。需讨论量化误差和 K×T 成本。

17. 迁移想法

VGGT/Depth Pro/YOLO 驾驶流程

改动：在条件序列加入可行驶距离、YOLO动态目标TTC与稀疏占用token。预期：减轻单目深度歧义。假设：几何与图像时序对齐。对照：RGB-only、RGB+Depth、RGB+Depth+YOLO-TTC，固定1/5步，报告PDMS、NC、EP、延迟。

Qwen2.5-VL / VLA Agent

改动：保留Qwen视觉语言骨干，将动作区改为局部非因果block，添加分层数值码本，LoRA先训动作头，再接闭环GRPO。预期：复用现有SFT/GRPO并得到可调步数规划。验证：局部非因果是否破坏语言推理；能否避免122k全词表。实验：相同50k样本比较AR-Qwen、1步DFM、5步DFM，再给DFM加1/10规模GRPO，观察NC与EP。