DrivePI：空间感知 4D MLLM 中文学习简报

历史论文按新提示词重制版，不是新推荐 · CVPR 2026 · 2026-10-14

完整原文、逐节译文与关键解释均在离线ZIP中；解压后双击 index.html。本PDF集中呈现13项简报、创新点、算法、公式和固定commit源码定位。

1. 基本信息

标题：DrivePI: Spatial-aware 4D MLLM for Unified Autonomous Driving Understanding, Perception, Prediction and Planning
作者：Zhe Liu 等；机构：香港大学、引望智能、天津大学、华中科技大学。
会议：CVPR 2026，正式版页码 3688–3698；arXiv:2512.12799。
版本：CVPR 正式正文 11 页 + 官方补充 6 页。
官方代码：commit 8eb5808。代码、配置、训练/评估入口已发布；本次做源码静态分析和离线页面验证，没有运行训练或推理，不能称为复现。

2. 分类标签

自动驾驶 VLA、4D MLLM、多摄像机+LiDAR、BEV、三维 occupancy、occupancy flow、端到端规划、多任务学习、扩散规划。

3. 个性化推荐理由

它补足你“VGGT/Depth Pro/YOLO 得到几何，再交给 VLM”的流程中缺少的统一训练接口：DrivePI 把 BEV 几何 token 送入 Qwen2.5，同时从同一隐藏状态解码占用、流和轨迹。你已有 Qwen2.5-VL LoRA 经验，可直接比较“语言损失单独训练”与“语言+体素+流+规划联合反传”；自动驾驶视觉经验则能帮助你判断碰撞率、开环 L2 和 occupancy 指标各自的局限。

4. 一句话问题定义

在一个驾驶模型中，怎样既用语言回答“前方是什么、应该怎么开”，又输出可核查的 200x200x16 三维占用、逐体素速度以及未来 6 帧轨迹?

5. 方法流程

- 多相机+时序 LiDAR经 UniLION 视觉编码器得到 [B,180,180,384] BEV。
- 9x9 patch 内，以均值 token 为 Q、81 个局部 token 为 K/V 做交叉注意力，形成 60x60=3600 个视觉 token。
- 视觉 token 与语言 token 输入 Qwen2.5-0.5B；文本头自回归，视觉 token 切出后重建为 180x180 特征。
- 占用/流头输出 [B,200,200,16,17] 和 [B,200,200,16,2]；规划头输出 3 个命令分支、多个轨迹 anchor、每条 6x2 增量。
- 语言交叉熵、四项占用损失、加权流 L1、轨迹回归/分类/ego 状态损失联合反传；视觉编码器冻结。

6. 真正创新点：已有方法 vs DrivePI

环节	旧方法	瓶颈	DrivePI 改动	证据
VA / VLA 接口	VA 显式三维但不懂语言；VLA 输出文本/轨迹	交互与精度割裂	同一 MLLM 隐藏状态接文本、占用、流、规划四头	联合头相较视觉头：RayIoU +1.8 点，mAVE -0.18，L2 -0.52
输入	多见纯相机 VLA	度量几何弱	多相机+时序 LiDAR->BEV	OpenOcc RayIoU 49.3；但论文未给“去 LiDAR”独立消融
token 压缩	KxK 平均池化	抹去局部几何	池化 token 作 Q，局部 token 作 K/V 的自挖掘投影器	源码真实实现；论文未单列 projector 消融
空间语言数据	描述/QA 不对应体素真值	语言难落到 4D 网格	占用/流真值生成 560k QA，另有 84k 描述、24k 规划 QA	28k->560k 占用 QA：类别 14.3->59.2
规划	扩散规划常依赖 SparseDrive query	外部模块复杂	直接对命令条件 anchor 加噪并预测轨迹	nuScenes 有 ego status：L2 0.40 m、碰撞 0.11%

不是新贡献的部分：Qwen2.5、UniLION BEV、FlashOcc 式通道转高度、DDIM 调度器、focal/Lovász/L1 和 Transformer decoder 均为沿用组件。新意主要在统一数据流、细/粗粒度共同监督及 4D 文本数据引擎。

7. 核心算法一：BEV 自挖掘空间投影器

问题与衔接：180x180=32400 个 BEV 位置直接进 MLLM 过长；投影器将其压成 60x60=3600 token，同时保留每个 3x3（配置的 downsample_rate=9）区域内差异。

形状：输入 x:[B,32400,C=384]；重排为 [B*60*60,9,384]；均值 query 为 [B*3600,1,384]。多头数 C/64=6，每头 d=64；注意力矩阵 [B*3600,6,1,9]；输出 [B,3600,384]，随后 MLP 映射到语言隐藏维。

执行：LayerNorm->线性生成 Q/K/V->Q 除以 sqrt64->对 9 个局部位置 softmax->加权 V->合并 6 头。没有跨 patch 注意力，计算随 patch 数线性增长。

训练/推理：第一阶段仅训练投影器 1 epoch；第二阶段投影器、MLLM 和各头联合更新，视觉编码器冻结。推理同一前向，无采样循环。

A=softmax((QK^T)/sqrtd)，Y=AV。若一个 query 对两位置打分 [2,1]，softmax~=[0.731,0.269]；V=[10,0] 时输出 7.31，而平均池化仅为 5。

```
# 自行编写的示意伪代码，不是作者代码
patches = reshape(bev, B*3600, 9, C)
q = mean(patches, dim=1, keepdim=True)
y = softmax(Q(q) @ K(patches).T / sqrt(64)) @ V(patches)
tokens = reshape(y, B, 3600, C)
```

源码：CrossAttentionDropOutProj.forward, L11–50；SelfMiningMMProjector.forward_downsampler, L53–70。

论文/实现差异：论文用一般 KxK；配置具体为 3x3->9 个局部 token、3600 输出。源码在相似度减去 detached max 后 softmax，数值更稳定。

8. 核心算法二：三维占用与占用流联合头

问题：把语言模型中的视觉 token 还原成稠密体素语义与速度。

形状：视觉隐藏状态 [B,3600,C_l]，线性映射到每 token 9x384，再重排为 [B,384,180,180]；卷积得到 [B,256,200,200]（网格变换后）。占用输出 [B,200,200,16,17]；流输出 [B,200,200,16,2]，末维是平面 vx,vy。

数据：每样本按 nuScenes token 加载 BEV npz、占用 npz、流 npz、规划 npy；collator 分别堆叠并对文本 pad/truncate。

训练：占用 logits 转 [B,17,200,200,16]，计算加类别权的 focal（源码乘 100）、semantic scaling、geometric scaling 和 Lovász。流仅对 car/truck/trailer/bus/construction vehicle/bicycle/motorcycle/pedestrian 八类计算；真值速度范数为权重，零速度改为 0.01；最终流项源码再乘 0.5。梯度回到头、投影器和 MLLM，视觉编码器冻结。

推理：argmax 得体素类别，同时保留 vx,vy；不再计算真值损失。

L_flow = mean_i (w_i * |v_pred_i-v_i|1), w_i=||v_i||2，若 ||v_i||2=0 则 w_i=0.01。例：v=(2,0)，v_pred=(1.5,0.5)，L1=1，权重2，贡献2；静止体素同样误差只贡献0.01。

```
# 自行编写的示意伪代码
bev = linear(visual_tokens).reshape(B, 180, 180, 384)
feat = conv(bev)
occ = occ_mlp(feat).reshape(B,200,200,16,17)
flow = flow_mlp(feat).reshape(B,200,200,16,2)
loss = focal + semantic + geometric + lovasz + weighted_l1(flow)
```

源码：OCCHead 构造, L38–150；前向与损失, L152–255；样本加载, L101–218。

易错点：补充论文说“动态 1.0、静态 0.01”；源码先按流范数连续加权，零速度才替为0.01，并且总流损失还乘0.5。这不是完全相同的二值权重描述。

9. 核心算法三：命令条件的动作扩散规划头

问题：从 BEV/MLLM 特征预测多模态未来轨迹，同时避免仅回归平均轨迹。

形状：BEV 经卷积为 [B,128,180,180]；规划 3 个命令分支，每个分支 K 个 anchor，每条 6x2 位移。预测回归张量最终为 [B,3,K,6,2]，分类为 [B,3,K]，ego 状态为 10 维。

归一化与加噪：x 位移除 3 并截断 [-1,1]；y 先 (y+0.5)/8.1 再映射到 [-1,1]。训练从 DDIM 1000 步表中只采样 t in [0,39]，给 anchor 增加较小噪声。噪轨迹经正弦位置编码和时间调制，再以 BEV 为 key/value 进入解码器。

损失：先按命令选分支；把位移累加为绝对轨迹，选择与真值平均距离最小的 mode。该 mode 用掩码 L1 回归；所有 mode 用 focal 分类；另对 10 维 ego 状态做 L1。三者相加为 action loss。

推理：选择命令分支，再按 sigmoid 分类分数取 mode，最后对 6 个增量累加。公开实现没有论文文字暗示的完整 DDIM 多步反向循环；实际是对加噪 anchor 单次网络预测/打分。

q(x_t|x0)=N(sqrtalpha̅_t x0,(1-alpha̅_t)I)。源码用 scheduler.add_noise 实现。若 alpha̅_t=0.81、x0=0.5、epsilon=-1，则 x_t=0.9*0.5+sqrt0.19*(-1)~=0.014。

L_action=L_reg+L_cls+L_ego；L_reg=sum m|y_pred-y|/(summ+1)。分母 +1 防止全无效 mask 除零，但会轻微缩小有效样本损失。

```
# 自行编写的示意伪代码
anchor = choose_anchor(command)
t = randint(0, 40)
x_t = ddim.add_noise(normalize(anchor), noise, t)
feat = decoder(posenc(x_t)+time_embed(t), bev)
delta, score = reg(feat), cls(feat)
best = argmin(distance(cumsum(delta), cumsum(gt)))
loss = masked_l1(delta[best], gt) + focal(score,best) + l1(ego)
```

源码：头与 DDIM, L91–246；加噪与预测, L335–446；best-of-K、损失与解码, L474–542。

10. 数学公式逐式详解

公式 (1)：总损失

L_total=lambda1L_llm+lambda2L_occ+lambda3L_flow+lambda4L_action

lambda 默认全为1。L_llm 是右移标签后的 token 交叉熵；L_occ 在公开实现实际为 focalx100、semantic、geometric、Lovász 四项之和；L_flow 为带速度范数权重的 L1；L_action 为轨迹 L1、mode focal、ego L1。代码先把占用/流加到 llm_output.loss，再加 planning loss，因此梯度共享 MLLM 与投影器。损失汇总 L650–782。

交叉注意力

A=softmax((QK^T-max(QK^T))/sqrtd)，Y=AV

Q:[BP,h,1,d]，K/V:[BP,h,9,d]，A 在最后的9位置维 softmax，Y:[BP,h,1,d]。减 max 不改变 softmax 概率，只避免指数溢出；max 被 detach，不让稳定化项参与梯度。

占用复合目标

L_occ=100L_focal+L_sem+L_geo+L_lovasz

focal 聚焦难体素；semantic scaling 约束各语义类精确率/召回；geometric scaling 强化空/非空结构；Lovász 是 IoU 的可微替代。组合兼顾类别不平衡、几何边界和最终 IoU。小例：易空体素概率0.99会被 focal 降权，错分行人则保留大梯度。

best-of-K 规划

k*=argmin_k mean_t ||sum_{tau<=t}Deltay_pred_{k,tau}-sum_{tau<=t}Deltay_tau||2

比较的是累积轨迹而非单步增量，因此早期方向错误会持续影响后续距离。只回归最接近的 mode，并用分类头学习选中它，避免所有 mode 都向平均值塌缩。

11. 实验与证据

- OpenOcc：OccScore/RayIoU=49.3/49.3，mAVE=0.509；占用显著强于对比方法，但 F-Occ/CascadeFlow 的 mAVE 0.491/0.470 更低，不能说流指标全面第一。
- nuScenes 规划：使用 ego status 为 0.40 m/0.11%；默认无 ego status 为 0.49 m/0.38%。比较时不可混用设置。
- QA：60.7%，比 OpenDriveVLA-7B 的58.2高2.5个百分点。
- 联合训练提高视觉指标但 QA 从61.2降到60.7，说明多任务仍有竞争。
- 证据边界：以上为论文报告；源码位置为静态分析；本次未下载数据/权重执行模型。

12. 局限与适用范围

作者报告：固定多任务权重不最优；没有强化学习。源码推断：训练依赖预生成 UniLION BEV，而非仓库内端到端从原始相机/LiDAR开始；配置含绝对占位路径，需手工准备数据；公开动作头是 anchor 加噪后的单次预测，称“扩散”时不要想象完整多步采样。适用：同步多相机+LiDAR、nuScenes/OpenOcc 栅格。纯相机、长时闭环与域外天气需要额外验证。

13. 前置知识

- BEV：把多传感器信息放到统一地面坐标，决定 token 的度量语义。
- 3D occupancy：每体素分类为空或语义类，比框更细。
- occupancy flow：为占用体素预测平面速度，连接感知与动态预测。

- 交叉注意力：query 从局部 K/V 选择信息，是空间投影器的核心。
- 扩散/多模态轨迹：以噪声和多个 anchor 表示多种未来，避免均值轨迹。

14. 30–60 分钟学习路线

- 0–8 分钟：图1/图2，画清 VA、VLA、DrivePI 三条数据流。
- 8–20 分钟：读3.1与空间投影器，必须手算 [180,180,384]->[3600,384]。
- 20–35 分钟：读补充细粒度头与源码 occ_head.py 171–255。
- 35–48 分钟：读动作头 335–446，回答“为何只采 t<40”。
- 48–60 分钟：核对表1、2、5；思考题：若移除文本损失，为什么占用和规划会同时变差?

15. 代码学习任务与最小路线

- self_mining_resampler.py L11–70：逐行标注 Q/K/V shape。
- occ_head.py L152–255：检查 17 类、16 高度、流 mask 与0.01静态权重。
- action_diffusion_head.py L335–542：画出 anchor->加噪->分类/回归->累加轨迹。

官方训练入口为 run_train_occ_action_llm_8_gpus_final.sh，配置说明论文实验使用 8xL40S；这是完整训练资源，不是单次推理估算。依赖 nuScenes、OpenOcc、nuScenes-QA、UniLION 预生成 BEV、占用/流/规划标签和 checkpoint。最小静态复现先只加载一条 npz 验证形状；真正推理需要公开权重及完整数据路径。

16. 面试价值

问1：为何文本头能改善占用与规划？共享 MLLM 隐藏状态接受语义监督，能把 BEV 特征对齐物体、状态和动作概念；消融显示 RayIoU +1.8点、mAVE -0.18、L2 -0.52，但 QA 略降，说明不是免费收益。

问2：DrivePI 的 flow loss 和论文文字完全一致吗？不完全。论文描述动态1、静态0.01；代码只对八类物体，权重取真值速度范数，零速度置0.01，末尾还乘0.5。回答时要区分论文抽象与实现。

17. 迁移想法

给 VGGT/Depth Pro/YOLO：在现有点云/深度融合后的 BEV 后加入 DrivePI 式 3x3 自挖掘投影器，把3600几何 token 送入 Qwen2.5-VL LoRA；保留占用头作为辅助监督。预期减少纯语言模型的几何幻觉。验证假设：显式体素监督是否提升“指定坐标物体/速度”QA。最小对照：相同数据与LoRA，A=平均池化+文本CE，B=交叉注意力+文本CE，C=B+占用/流损失；比较QA、RayIoU及推理延迟。

给未来 VLA Agent：把当前固定 lambda 换为不确定性加权或 GradNorm，再在规划头之后接安全约束奖励的离线/在线 RL。最小实验只在 10% nuScenes 训练：固定权重 vs GradNorm，记录四项梯度范数、QA、RayIoU、mAVE、L2，先验证是否缓解文本与视觉任务竞争。