UniVLA：统一视觉—语言—动作模型中文学习简报

历史论文按新提示词重制版，不是新推荐 · ICLR 2026 · 2026-10-19

完整原文逐页图、除参考文献外逐节译文与关键解释均在离线 ZIP 中；完整解压后双击 index.html。本 PDF 集中呈现 13 项学习简报、创新点、算法、公式与固定 commit 源码定位。

1. 基本信息与一句话问题定义

论文：Unified Vision-Language-Action Model（UniVLA）｜版本：arXiv:2506.19850v1（2025-06-24，18 页）｜会议：ICLR 2026｜代码：baaivision/UniVLA，固定 commit a91ee5f…。

分类标签：机器人 VLA、统一 token 空间、自回归 Transformer、world model（世界模型）、DCT/FAST 动作 token、视频后训练、长时程操作、自动驾驶迁移。

一句话问题定义：如何避免“VLM 提取语义特征、独立动作头输出控制”的晚融合瓶颈，让视觉、语言、动作在同一个因果 token 序列中学习，并把无动作标注的机器人视频转化为可迁移的策略先验？

个性化推荐理由：这篇论文把你已有的 Qwen2.5-VL 微调经验与未来 VLA Agent 连接起来：核心仍是 causal LM 与 mask，但输出从文字扩展到图像 token 和动作 token。它也提供一个与 VGGT/Depth Pro/YOLO 路线互补的视角——前者显式恢复几何，UniVLA 则用视频 next-token loss 隐式学习动力学。NAVSIM 试验还能直接帮助判断“前视图 token 策略”与“BEV/多传感器显式 3D”各自缺什么。

2. 方法流程

- 离散化：图像经 Emu3 VQ tokenizer 变成二维视觉 token；连续 action chunk 先做相邻帧差分、百分位归一化，再经 DCT、量化与 BPE 压缩成可变长 FAST token。
- 统一序列：文本指令放在序列开头，之后按时间交错视觉与动作：T, I1, A1, I2, A2, ⋯。boi/eoi 与 boa/eoa 标出边界。
- 世界模型后训练：输入 T,I1,⋯,I□，仅视觉 token 参与交叉熵；模型学语言条件下的未来视觉动态，无需动作标签。
- 策略微调：从后训练 checkpoint 初始化，输入交错序列，但默认只让动作 token 参与交叉熵；梯度穿过整个 Transformer，更新全参数。
- 推理：将当前观察编码后，自回归生成限定在动作词表内的 token，遇到 eoa 停止，再由 FAST 逆 BPE、逆量化与 IDCT 还原连续 action chunk。

以下第 4–6 节分别把这三个决定结果的算法拆到实现级；第 7 节逐式解释数学目标。

3. 真正创新点与已有方法对比

模块	既有方法	瓶颈	UniVLA 改动	监督/复杂度	论文证据
跨模态架构	ViT/VLM 编码图像，独立动作头回归、离散预测或 flow matching	晚融合；视觉与动作不在同一生成空间，难以直接复用视频生成能力	视觉、语言、动作全部转为共享词表中的离散 token，用同一 8.5B 自回归 Transformer 建模	统一 next-token CE；代价是视觉 token 序列很长	无需后训练时，加入视觉预测将 CALVIN 1.46->4.42、LIBERO 48.5->88.7
视频后训练	动作预训练依赖不一致的跨机器人动作空间；或潜动作/独立视频生成器	动作标签难统一；潜动作增加模型链路，独立生成器和策略割裂	把文本指令视作广义动作，序列 T,I1,⋯,I□ 只监督视觉 token	不需要动作标签；主文 30k 步、附录 50k 步（原文冲突）	表 4：世界模型后训练使 LIBERO 48.5->94.2、CALVIN 1.46->4.61；动作预测后训练反而下降
动作表示	逐维分箱会让高频连续轨迹产生很长 token 串	序列长、时序相关性利用不足	FAST：DCT 转频域，量化后用 BPE 压缩，映射到语言词表末端 1,024 个 ID	可变长 token；需要已知 H 与 d 才能 IDCT	代码真实执行 DCT->round->BPE，推理再 IDCT
时间组织	静态 I->A 或只看当前帧	忽略动作后状态变化与短历史	以 MDP 顺序交错 I□,A□，并允许视觉损失与历史窗口	序列长度随帧数增长	加入历史由 4.26->4.61；超过最近历史后收益递减

创新边界

VQ 图像 tokenizer、Emu3 自回归骨干、FAST 的 DCT+BPE、标准 causal cross-entropy 都来自既有工作，不能包装成本文原创。本文真正的新意是把这些部件组织成同一词表与交错因果序列，并证明“语言条件视频世界模型后训练”能显著改善动作策略。自动驾驶只是一项初步迁移实验，也不是方法的主要算法创新。

4. 核心算法一：视觉—语言—动作统一交错序列

4.1 问题与衔接

该算法把异构输入变成 causal LM 能处理的一维序列。上游是文本 tokenizer、VQ 图像 tokenizer、FAST 动作 tokenizer；下游是统一 Transformer 的 next-token loss。

4.2 输入、输出与 shape

设 batch 为 B，交互步数为 T，图像高宽为 HxW，VQ 压缩率 8，视觉网格约为 H/8xW/8；每步动作窗口 H_a，动作维度 D_a，FAST 压缩后长度 N_a（可变）。单样本形如：

[BOS, text(N_t), BOI, shape, image tokens(N_v), EOF, EOI, BOA, action tokens(N_a), EOA, …]

训练输入张量为 input_ids, attention_mask, labels in Z^(BxN)；N 不超过配置的最大位置长度。论文后训练写 6,400，公开 config 为 5,120，属于论文与公开默认配置差异。

4.3 预处理、mask 与前向

- 根据数据集帧率选择步长，随机截取 Txaction_frames 个原始帧。
- 每隔 action_frames 取一帧作为交错观察。
- 将 VQ token 格式化为 boi + frames*height*width + img + tokens + eof + eoi。
- 将 FAST token 包在 boa/eoa 中，交错拼到图像之后。
- attention_mask=1 表示真实 token；因 causal attention，第 i 个 token 只能看到 0…i。
- labels=-100 的位置不计算 CE。策略微调默认只把动作 span 写入 labels；若联合视觉预测，则视觉 span 也写入。

4.4 训练与梯度

损失虽只在动作或视觉位置产生，梯度仍从这些位置经过所有可见的历史文本、图像、动作表示反传到整个 Transformer。论文明确使用全参数训练；没有“冻结 VQ 以外的某些层”的说明。VQ token 在数据预处理时已离散化，公开数据管线通常读取缓存的 .npy code，因此 VQ 编码器不在策略 loss 的反向图中。

4.5 推理差异

推理不再构造 labels。输入当前文本与视觉 token 后自回归生成动作 token；公开脚本强制 logits 只能从动作 token 区间或 eoa 选择，并以贪心方式生成，最多 50 个新 token。

4.6 小形状例子

若 B=1、T=2、每帧视觉 token N_v=4、两段动作 token 长度分别 3 和 2，则忽略边界 token 时序列主体为 [T(2), I1(4), A1(3), I2(4), A2(2)]，主体长度 15。只训练动作时，label mask 为 [xx, xxxx, ✓✓✓, xxxx, ✓✓]；第二段动作 token 的梯度能依赖此前文本、两帧视觉和第一段动作。

4.7 自行编写的示意伪代码（不是作者原代码）

```
ids = [BOS] + text_tokens
labels = [-100] * max_len
for t in range(T):
image_span = wrap_image(vq(frame[t]))
action_span = wrap_action(fast(action_chunk[t]))
ids += image_span + action_span
labels[action_positions(action_span)] = action_span
ids, labels = pad(ids), pad(labels, value=-100)
loss = causal_cross_entropy(model(ids), labels)
```

4.8 官方源码映射

- train/datasets.py L175–279：采样、交错拼接与 action-only label span。
- train/datasets.py L379–427：boa/eoa 包装、视觉边界与网格字符串。
- train/train_moe.py L39–188：参数、模型/数据集分派、Trainer 与全流程入口。

4.9 容易误解处

“共享词表”不等于三种模态用同一个 tokenizer：视觉、语言、动作各自编码，之后映射进一个统一 ID 空间。公开代码中动作 BPE ID 通过 pad_token_id-1-id 反向映射到语言词表尾部；这是一项具体实现约定，不是论文公式的一部分。

5. 核心算法二：FAST 动作 token 化与反解

5.1 问题与衔接

连续动作有强时间相关性。若每个时刻、每个维度独立分箱，token 数约为 H_axD$_a$。FAST 先用 DCT 把平滑轨迹能量集中到低频，再量化成字符流，最后由 BPE 合并常见频率模式，得到可变长 token。

5.2 输入输出与 shape

输入 A in R^(BxH_axD_a)。沿时间轴做 DCT 后 shape 不变；展平为每样本 H_aD_a 个整数，再经 BPE 得到长度 N_a 的 token 序列。解码需提供 H_a 与 D_a，输出回到 R^(BxH_axD_a)。

5.3 预处理与前向

- 论文先用动作相邻帧差分，并按第 1/99 百分位做稳健归一化。
- 沿时间维做正交归一 DCT。
- 乘 scale=10 并四舍五入量化。
- 减去训练时的 min_token，使整数非负，映射为 Unicode 字符串。
- Byte-level BPE 将常见连续字符合并为最多 1,024 类 token。

5.4 训练阶段

FAST tokenizer 在动作数据上独立 fit；策略训练本身不更新 DCT 或 BPE。Transformer 对动作 token 做分类 CE，梯度只更新策略模型。

5.5 推理阶段

将生成 token 交给 BPE decode，字符转整数，加回 min_token；超出 H_aD_a 就截断，不足补零；reshape 为 H_axD$_a$，除以 scale，沿时间轴 IDCT 得到动作。再用数据集统计反归一化并累积相对差分，才得到可执行控制量。

5.6 极小数值例子

取单维 H_a=2，动作 A=[1,3]。正交 DCT-II 给出 c0=(1+3)/sqrt2=2.828，c1=(1-3)/sqrt2=-1.414。scale=10 后量化为 [28,-14]。若 min_token=-20，字符码为 [48,6]；BPE 可能合并成 1–2 个 token。解码恢复 [28,-14]，除以 10 后 IDCT 约回 [0.99,2.97]，误差来自量化。

5.7 自行编写的示意伪代码（不是作者原代码）

```
coeff = dct(action_chunk, axis=time, norm="ortho")
q = round(coeff * 10)
chars = to_chars(q.flatten() - min_token)
tokens = bpe.encode(chars)

q_hat = from_chars(bpe.decode(tokens)) + min_token
q_hat = pad_or_trim(q_hat, H_a * D_a).reshape(H_a, D_a)
action_hat = idct(q_hat / 10, axis=time, norm="ortho")
```

5.8 官方源码映射

- processing_action_tokenizer.py L42–57：DCT、量化、字符化、BPE encode。
- L59–113：BPE decode、截断/补零、reshape、IDCT。
- L115–175：tokenizer fit、值域检查与 BPE 训练。

5.9 论文与实现差异

论文只概括“DCT 后离散化”，真正的 scale=10、字符编码、BPE、过长截断/过短补零都来自公开源码静态分析。论文说动作词表为 1,024；代码确实配置 1,024，但最终每个 chunk 的 token 数可变。

6. 核心算法三：语言条件世界模型后训练与动作推理

6.1 问题与衔接

跨机器人动作空间不一致，使动作后训练难迁移；视频却共享可观察的物理变化。UniVLA 因而用“指令+帧序列->下一视觉 token”学习动力学，再把该 checkpoint 用于动作微调。

6.2 输入输出与 shape

后训练样本包含文本 T 与 6 个关键帧。256x256 图像、VQ 压缩率 8 时，每帧网格约 32x32=1,024 个视觉 token，六帧约 6,144 个视觉 token，再加文本与边界 token；论文因此给出最大长度 6,400。输出 logits 为 BxNx|V|，但 loss mask 只选择视觉 token。

6.3 数据处理、采样与 mask

数据预处理按数据集采集频率选择间隔，使关键帧约相隔 1 秒；不足 6 帧或无文本的序列被过滤，Kuka 随机截到 10 万条。公开 Emu3WorldModelDataset 再根据路径匹配 FPS，抽取交错帧，拼成 T,I1,⋯,I⊠，并把非视觉 label 全设为 -100。

6.4 训练阶段

模型由 Emu3 VL 对齐 checkpoint 初始化，使用全参数训练。主文报告 batch 64、30k 步；附录报告 32xA100 40GB、50k 步、4–5 天。两处不一致必须由复现实验自行确认，不能选择性改写。

6.5 策略推理

推理时，将任务文本与当前 VQ 观察输入模型。ActionIDConstraintLogitsProcessor 把所有非动作 token 的分数置为 -inf；生成配置 do_sample=False，到 eoa 停止，最多 50 token。去掉 prompt 与终止 token 后，将词表尾部的 ID 反映射为 FAST ID，再解码出 HxD 连续动作。

6.6 小形状例子

若视觉词表区间为 [100,199]，序列共有 N=12 个 token，而视觉 token 位于索引 3–6 和 8–11，则 labels 只在这 8 个位置保留目标 ID，其余为 -100。CE 的有效分母是 8 个位置，不是 12。策略推理若动作 token 允许集合为 {90,⋯,99,eoa}，即使语言 token 的原始 logit 最大，也会被 mask 为 -inf，因此不会生成文字。

6.7 自行编写的示意伪代码（不是作者原代码）

```
# world-model post-training
ids = interleave(text, vq(frame1), ..., vq(frame6))
labels = where(is_visual(ids), ids, -100)
loss = model(ids, labels=labels).loss
loss.backward() # full model

# policy inference
prompt = encode(text, current_images)
tokens = greedy_generate(prompt,
allowed=action_vocab union {EOA}, stop=EOA, max_new_tokens=50)
actions = fast_decode(remap_to_fast_ids(tokens), H, D)
```

6.8 官方源码映射

- world_model_pretrain.py L11–170：帧数过滤、各数据集间隔、Kuka 上限和元数据合并。
- train/datasets.py L459–553：世界模型数据权重、交错帧、vision-only label mask。
- inference_action.py L22–39：动作词表 logits 约束。
- inference_action.py L71–127：贪心生成、50-token 上限、ID 反映射与 FAST decode。

6.9 公开实现限制

脚本包含作者内部绝对路径，需要改配置后才能运行；仓库公开了训练与评估入口、模型权重链接，但没有把论文所用全部预处理数据打包。这里是论文阅读与源码静态分析，未下载 8.5B 权重、未训练、未在仿真器执行，不能称为“已复现”。

7. 数学公式逐式详解

7.1 世界模型转移目标

$$P(s_{t+1} \mid s_t, a_t)$$

符号与维度：s_t 是时刻 t 的环境状态；实现中不直接观测完整状态，而用视觉 token L_V^t 近似；a_t 可为低层动作，论文后训练把语言指令 L_t^1 视作广义动作/条件。左侧是下一状态条件分布，右侧提供当前状态和控制条件。

计算顺序：文本和当前/历史帧先离散化，Transformer 以 causal mask 产生下一视觉 token 的 logits，softmax 得到离散条件分布。用生成式分布而非像素 L2，可复用预训练生成模型并表达多模态未来。梯度推动模型提高真实下一视觉 token 的概率。

小例子：若某位置真实 token 为 2，而预测概率 [0.1,0.2,0.7]，该位置 CE=-log 0.7~=0.357；只有视觉位置累加。

源码：vision-only labels L522–547。论文没有进一步给出状态空间推导；以上为基于实现的直观解释。

7.2 论文公式 (1)：世界模型序列

$$S_V=\{L_t^1,L_V^1,L_V^2,\cdots,L_V^t\} \quad (1)$$

L_t^1 是一次性指令 token，shape 约为 N_t；每个 L_V^i 是一帧视觉 token，shape N_V。拼接后 $N=N_t+tN_V$+边界 token。右侧顺序保证预测第 i 帧只能依赖文本与先前帧。训练并不显式回归 s，而是做视觉 token CE。

为何不是动作条件视频：后训练数据可没有动作标注，语言提供高层意图，使 SSV2 等视频可用。代价是同一语言下的低层动作多样性可能令未来不确定。

例子：指令 token [T]、三帧分别 [11,12]、[13,14]、[15,16]，序列为 [T,11,12,13,14,15,16]。训练位置 3 的 token 13 可看见 T,11,12，但看不见 14–16。

7.3 论文公式 (2)：策略交错序列

$$S_a=\{L_t^1,L_v^1,L_a^1,L_v^2,L_a^2,\cdots,L_v^t,L_a^t\} \quad (2)$$

L_a^i 是第 i 步 action chunk 的可变长 FAST token。视觉先于同时间步动作，因而动作能条件于当前观察；下一视觉又能条件于刚执行的动作，保持 MDP 的因果顺序。动作 token loss 推动模型学 $pi(a_t|$指令,历史观察,历史动作)。

例子：[T,I1,A1,I2,A2] 中 A2 的预测能利用 T,I1,A1,I2；若只保留 action labels，I token 本身不直接产生 loss，但仍作为上下文接收来自动作位置的梯度。

7.4 自回归交叉熵（论文文字目标的显式写法）

$$L = - (1/|M|) \sum_{i \text{ in } M} \log p_{theta}(x_i \mid x_{<i})$$

说明：这是对论文“标准 next-token cross-entropy”的显式化，不是作者另列的编号公式。x in Z^{BxN}；M 是有效监督位置。世界模型时 M=视觉 token，策略微调时 M=动作 token。softmax 沿词表维 |V| 计算；-100 位置被忽略。

为何不用 MSE：所有输出已离散化，CE 与分类词表直接匹配；MSE 会错误地假设 token ID 之间有欧氏距离。对参数的影响是提高真实 token logit、压低其他 token logit。

数值例子：两个有效位置真实概率分别 0.8、0.5，则 L=-(log0.8+log0.5)/2~=0.458。

源码：labels 的构造见 动作/视觉 span L245–279；模型由 Hugging Face causal LM/Trainer 计算标准 shift CE。

7.5 DCT 与 IDCT

$$c_k=alpha_k \sum_{t=0}^{H-1} a_t \cos[pi(t+1/2)k/H]; \quad \hat{a}=IDCT(round(10c)/10)$$

每个动作维度独立沿时间轴变换。c 与 a 形状相同，$alpha_k$ 是 norm="ortho" 的归一系数。平滑动作的低频 c_k 较大而高频多接近零，BPE 因此容易压缩重复模式。量化让模型变成 token 分类，但引入最大约半个量化步长的频域误差。

与逐维分箱比较：逐维分箱保留每个时间点的 token，序列长度固定为 HxD；DCT+BPE利用时间相关性换取更短序列，代价是一次 token 错误可能影响整个 chunk。

源码：DCT encode 与 IDCT decode。

8. 实验与证据

问题	关键证据	能证明什么	不能证明什么
统一视觉学习是否有用	无后训练时，视觉预测使 CALVIN 1.46->4.42、LIBERO 48.5->88.7	视觉生成监督本身能改善动作学习	不能排除更大算力/更长序列带来的因素
哪种后训练最好	世界模型：LIBERO 94.2、SimplerEnv 64.6、Long 89.2、CALVIN 4.61；动作预测后训练下降	语言条件视频动态比跨数据集动作 token 更可迁移	没有系统扩展曲线，也没有同计算量的大型 latent-action 对照
最终策略表现	LIBERO 平均 95.5%、Long 94.0%；CALVIN ABCD->D 4.63；SimplerEnv 69.8%	在三类仿真基准上表现强	不等同于真实机器人稳健性；论文的真实任务未给充分基线表
自动驾驶迁移	前视相机 PDMS 81.7；多相机/BEV 基线约 83–84	统一 token 模型可迁移到驾驶	并未超过多传感器 BEV 方法，也未使用驾驶视频预训练

证据层级：上述数值来自论文报告；代码位置来自固定 commit 的源码静态分析；本学习包未训练模型、未运行 CALVIN/LIBERO/SimplerEnv/NAVSIM，故无实际复现结果。

9. 局限与适用范围

- 8.5B 模型加高分辨率离散视觉 token，训练成本高；附录给出 32xA100 40GB、4–5 天。
- 主文 30k 与附录 50k 后训练步数矛盾；公开 config 最大长度 5,120 与论文 6,400 也不一致，需要复现时确认。
- 自回归逐 token 生成动作，延迟可能高于小型并行动作头；公开脚本最多生成 50 个动作 token。
- 世界模型只在 token 空间做 next-token prediction，没有显式几何、碰撞约束或闭环奖励；高视觉似然不保证安全动作。
- NAVSIM 仅前视相机、PDMS 81.7，低于表中多相机/BEV 方法；自动驾驶属于初步可行性，不应过度外推。
- 仓库依赖作者内部路径与预处理缓存；权重和脚本公开不等于论文所有训练数据可一键复现。

10. 前置知识

- Causal Transformer：shifted next-token CE、causal mask、KV cache。
- VQ/VQ-VAE：将图像网格量化为码本索引及空间压缩率。
- DCT/IDCT 与 BPE：频域压缩、量化误差、可变长 token 化。
- MDP 与行为克隆：状态、动作、转移、策略，以及离线示范的监督目标。
- 机器人基准指标：CALVIN 连续任务长度、LIBERO 成功率、NAVSIM PDMS 组成。

11. 30–60 分钟学习路线

- 0–8 分钟：看图 1/图 2与表 4，先回答“统一 token 与世界模型后训练各解决什么问题”。
- 8–20 分钟：读 3.1/3.2，手写 S_v 与 S_a 的排列，并标出 vision-only/action-only loss mask。
- 20–32 分钟：走一遍第 5 节两步动作的 DCT 数值例子，理解为什么 FAST 能压缩平滑轨迹。
- 32–45 分钟：对照 train/datasets.py 的 L175–279 与 L459–553，确认论文序列在代码中如何变成 input_ids/labels。
- 45–60 分钟：读 inference_action.py，画出“VQ观察->受限生成->FAST解码->连续动作”的推理图，再评估延迟和安全缺口。

12. 代码学习任务

- 任务 A：mask 单元测试。构造 B=1、T=2 的假 VQ/FAST token，不加载 8.5B 权重，只实例化序列拼接逻辑；断言 action-only 时仅 boa…eoa 区间不是 -100。
- 任务 B：FAST 误差曲线。用正弦、阶跃、随机动作各 100 段，统计不同 scale（5/10/20）下 token 长度和重建 MAE，验证压缩—精度权衡。
- 任务 C：历史窗口消融复刻。从 CALVIN 预处理 pickle 取固定 100 样本，比较当前帧、1 历史帧、2 历史帧的序列长度、显存与动作 NLL；先验证数据管线，再决定是否训练。
- 任务 D：源码差异清单。把论文超参数与 shell/config 实参逐项对齐，重点确认 30k/50k、5,120/6,400、vision_loss_weight、action chunk 和相机视角。

13. 面试问题

问题 1：UniVLA 的“统一”与 OpenVLA 之类把视觉特征接入 LLM 有何本质差别?
参考回答：后者通常在连续视觉特征与语言模型之间做投影/融合，再由动作头输出；UniVLA 把视觉与动作都离散成与文本同属一个 token ID 空间的序列，统一使用 causal next-token loss。因此它可以原生生成视觉、文字、动作并共享视频后训练，但视觉 token 更长、生成延迟更高。

问题 2：为什么动作预测后训练会变差，而世界模型后训练有效?
参考回答：跨机器人数据的动作维度、控制频率和语义不一致，即便都 token 化，同一 token 模式不一定具有相同物理含义；视觉状态变化更具跨 embodiment 的共享结构。语言条件世界模型不依赖动作标签，学习“意图下环境如何变化”，更容易迁移。表 4 的负/正增益支持这一解释，但不是严格因果证明。

14. 迁移到现有项目的具体实验

14.1 VGGT + Depth Pro + YOLO：几何 token 辅助世界模型

为每帧提取 VGGT camera/point map、Depth Pro metric depth、YOLO 目标框；不要一开始把稠密点云全 token 化，而先量化成 K=64 个“几何摘要 token”（相机位姿、目标中心深度、局部占用）。在序列中插入 I_t,G_t,A_t，比较三组：UniVLA 原版；仅添加 G；添加 G 并预测 G_{t+1}。指标除 action success 外增加跨帧深度一致性、碰撞率和 token/延迟。它直接检验显式 3D 是否补足纯视频 world model 的几何弱点。

14.2 Qwen2.5-VL：低成本原型

不复制 8.5B Emu3 全套。先冻结 Qwen2.5-VL 视觉编码器，新增 1,024 个 FAST 动作 token，仅训练 LoRA 与新 embedding/head；数据格式复用 T,I,A 与 action-only mask。第二阶段加入一个小型 VQ/depth token 辅助头，让视觉未来预测作为 0.1–0.5 权重正则。这样可分离验证“统一动作词表”和“视觉预测正则”两项收益。

14.3 未来 VLA Agent：SFT→闭环偏好/RL

先用 UniVLA SFT 得到可执行策略，再让环境/世界模型对 K 条动作候选评分（成功、碰撞、进度、舒适）。用 DPO/GRPO 更新动作 token 策略，但保留视觉 world-model loss 作为稳定项。关键对照：只做 GRPO、GRPO+视觉 loss、冻结 world-model 层。监控 KL、动作 token 熵、长时程成功率和视觉预测退化，以验证论文所述“与强化学习结合”的未来方向。

14.4 自动驾驶最小实验

在 NAVSIM 先严格复刻前视图+ego status->8帧轨迹 token，再加入多相机或 BEV token。固定模型规模与训练步数，比较 PDMS、TTC、DAC、推理延迟。若 BEV 组显著增益，即说明纯前视自回归 token 尚缺显式空间表示；若世界模型预训练提升长尾 TTC，则证明机器人视频范式可迁移到驾驶视频。

15. 源码证据与复现声明

固定 commit：a91ee5f269d7ad46d46635ee6481d2eb655b4af9。本简报实际读取了该 commit 的数据集构造、FAST tokenizer、训练入口、动作推理脚本与配置。

论文报告结果：第 8 节所有 benchmark 数值。源码静态分析：第 4–7 节的具体 ID 映射、mask、贪心生成、截断/补零与行号。实际运行验证：未进行模型训练、权重推理或仿真评测；本次只验证离线阅读包与代码静态一致性，因此不声称“复现成功”。