GLUEMAP：把前馈局部几何粘合为全局 SfM

新论文推荐 · CVPR 2026 · 2026-10-21

对应离线 ZIP：完整解压后双击 index.html。本 PDF 包含 13 项学习简报、创新对比、四个实现级算法、逐式数学解释和固定 commit 源码；完整原文与逐节译文在 ZIP 中。

1. 基本信息

论文：GLUEMAP: Global Structure-from-Motion Meets Feedforward Reconstruction；会议：CVPR 2026；版本：arXiv:2605.26103v2，21 页；官方实现：colmap/gluemap@adc9e4b。

证据分层：实验数值来自论文报告；代码位置来自对固定 commit 的源码静态分析；本阅读包未安装模型权重、未跑训练或完整数据集，因此不声称复现。

2. 分类标签

三维视觉 · 全局 Structure-from-Motion · 前馈三维重建 · 视图图 · 旋转平均 · 相似变换平均 · Bundle Adjustment · π^3 · VGGSfM · COLMAP/GLOMAP。

3. 个性化推荐理由

你已有 VGGT + Depth Pro + YOLO 的“检测—深度—几何”能力，但最容易缺的是跨很多视图的全局一致性：相对姿态怎样形成可靠视图图、局部深度如何跨子图定尺度、低重叠时 BA 没有实体轨迹怎么办。GLUEMAP 正好补上这一层。它不要求把 VGGT/π^3 推理扩成超长全局 Transformer，而是把前馈模型当作局部几何先验，再让传统优化承担大规模一致性。

对自动驾驶也很有价值：多相机/多时刻数据常含运动模糊、纹理缺失、视角重复与超大图半径。其“稀疏视图图 → 局部星图 → 全局融合 → 增强 BA”可迁移为离线地图构建或训练数据几何清洗骨架。

4. 一句话问题定义

在传统 SfM 会因低纹理/低重叠/低视差/对称结构失败、全前馈重建又受显存与全局注意力噪声限制时，如何把局部前馈三维先验稳定地“粘合”为可扩展、准确、全局一致的重建？

5. 方法流程

- 视图图初始化：SALAD 每图检索固定候选；Doppelgangers++ 判别真共视与视觉重影；动态阈值确保尽量连通。
- 局部星图推理：每张图作中心，仅与一阶邻居组成最多 26 帧的星图；π^3 回归姿态/深度/焦距，VGGSfM 建轨迹；深度往返一致性产生可见性权重。
- 全局运动平均：内参中位数、SO(3) 旋转平均、每星图一个尺度的相似平均，将局部坐标系统一到全局。
- 增强 BA：混合 SIFT、前馈轨迹和可越界/负深度的虚拟轨迹；联合细化姿态、内参和点。

实现入口见 算法 1 至 算法 4，数学细节见 第 10 节。

6. 真正创新点

模块	已有方法	具体瓶颈	GLUEMAP 修改	监督/复杂度	论文证据
前馈输入组织	所有图像进入全局 Transformer，或顺序循环更新	显存二次增长；大图半径时无关图像相互干扰；循环错误不可逆	把稀疏视图图拆成一阶星图，独立并行推理	候选边 O(cN)，局部输入至多 26 帧	图 3：前馈随半径增大持续退化，GLUEMAP 更稳；LaMAR 全前馈 OOM
局部结果合并	两视图平移平均；点图全局对齐	每边尺度噪声大、病态；全局对齐难扩展	每个局部星图只估一个尺度，先旋转平均再相似平均	Ceres 鲁棒优化；星内共享尺度	骨干消融：motion averaging 对所有骨干都有稳定收益
低重叠 BA	只有真实 SIFT/学习轨迹	低重叠时无法形成多视图轨迹，BA 欠约束或断裂	用局部/全局姿态与深度合成虚拟轨迹，允许画外与负深度观测	约 100 VT/星图；10% 由全局姿态条件化	SMERF：VT 防止跨房间漂移；AUC@1 在中/高密度从 20.3/30.9 提至 27.7/47.4
鲁棒图过滤	检索分数或局部匹配建立图	对称立面/房间产生 Doppelganger 边并使重建塌缩	DG 分数动态连通 + 前后深度一致性 VO 二次过滤/加权	DG 与 VO 均为静态/预测置信度，不需新标注	消融：ETH3D 仅 DG 足够；SMERF 必须 DG+VO

没有被包装成新贡献的部分：SALAD 检索、Doppelgangers++、π^3、VGGSfM、SIFT、Huber/Ceres、旋转平均和 BA 都是已有组件；论文新意主要在系统组合方式、星图尺度建模、可见性加权和虚拟轨迹增强。

7. 实验与证据

- ETH3D：GLUEMAP 在已标定/未标定设置均为最高精度；传统方法能工作时，它依然保留经典优化的高精度。
- SMERF：高密度 AUC@1/5/20 为 47.4/88.1/97.0，运动平均版为 30.9/82.9/95.7，显示 A-BA 尤其改善紧阈值精度。
- LaMAR：平均 AUC@1/5/20 从 AL+LG 的 10.9/30.1/46.0 提到 26.4/59.1/80.6；全前馈方法 OOM。
- 边界条件：CO3D 仅 10 张、场景几乎可被一次前馈覆盖时，π^3+BA 往往更好；IMC 输入 25 张或全量、特征足够密时，GLOMAP+SIFT 仍可能最优。

8. 局限与适用范围

- 依赖局部前馈重建质量；当前骨干为针孔相机训练，不支持鱼眼。
- 需要 SALAD、Doppelgangers++、π^3、VGGSfM 等多个模型，部署链较重。
- 虚拟轨迹和重复星图会带来额外推理/BA 成本；高帧率顺序数据可能冗余。
- 论文对纯旋转能力的表述存在原文矛盾，工程使用前需实测。
- 公开结果是静态实验报告；本次只读源码，未验证不同 CUDA/PyTorch/权重组合的可运行性。

9. 前置知识

- 针孔相机、SE(3)、相对姿态与相机中心。
- SfM 的视图图、特征轨迹、三角化与 BA。
- SO(3) 测地距离、旋转平均、尺度规约自由度。
- 前馈深度/姿态模型（VGGT、π^3）与 Transformer token 组织。
- 鲁棒损失（Huber/Arctan）和 Ceres 非线性最小二乘。

10. 数学公式详解

10.1 视图图分数与动态连通（式 1–2）

$$\alpha\boxtimes\boxtimes=DG(I\boxtimes,I\boxtimes)$$
$$\boxtimes\boxtimes\boxtimes\boxtimes=\boxtimes\boxtimes\cup\{(i,j)|\alpha\boxtimes\boxtimes>\delta\boxtimes, CC(i)\neq CC(j)\}$$

符号/维度：$I\boxtimes\in\boxtimes^{H\boxtimes\times W\boxtimes\times 3}$；α、δ 为标量；CC(i) 是离散分量编号。先对 O(cN) 候选算分，再按阈值 0.8、0.7…0.2 跨分量加边。

为什么这样写：固定高阈值会让低重叠场景断开；固定低阈值会吞入对称假边。只加“跨分量”边让阈值下降服务于连通，而非无限增密。与普通 top-k 图相比，它把拓扑连通性作为停止条件。

极小例子：A-B=0.92、B-C=0.73、A-C=0.18。δ=0.8 先加 A-B，C 独立；δ=0.7 再加 B-C 后连通并停止，A-C 永不加入。

参数影响：此阶段本身不反向传播；DG 权重来自预训练模型，输出决定后续输入图。源码入口：GluemapPipeline.run L84–122。

10.2 深度往返与传递重叠（式 4–10）

$$\varepsilon\boxtimes\rightarrow\boxtimes=||x-\Pi\boxtimes(T\boxtimes\rightarrow\boxtimes[D\boxtimes(\Pi\boxtimes(T\boxtimes\rightarrow\boxtimes[D\boxtimes(x)\pi\boxtimes\boxtimes^{1}(x)]))\pi\boxtimes\boxtimes^{1}(\cdot)])||\boxtimes$$
$$\tilde{o}\boxtimes\boxtimes\boxtimes=(H\boxtimes W\boxtimes)\boxtimes^{1}\Sigma\boxtimes\boxtimes(\varepsilon\boxtimes\rightarrow\boxtimes<\tau)，\quad o\boxtimes\boxtimes\boxtimes=\max_{path}\prod\tilde{o}_{pq}\boxtimes$$

形状：$D\boxtimes\in\boxtimes^{H\times W}$；$x\in\boxtimes^{2}$；三维点$\in\boxtimes^{3}$；ε、õ、o 为标量。softmax 不参与；阈值在像素维度 H×W 上形成布尔 mask，再求均值。

计算顺序：i 像素→i 相机三维→j 像素→j 深度三维→回投 i→像素误差→阈值计数→所有路径最大乘积。最大乘积可通过 −log 转为最短路径。

极小例子：4 个像素误差为 [0.3,0.7,2.2,4.1]，τ=1，则 õ=2/4=0.5。若 i→k→j 的边重叠 0.8、0.7，则路径乘积 0.56；直接 i→j 为 0.4，传递值取 0.56。

为什么不是匹配数：低纹理会让匹配数低估真实共视，深度一致性利用前馈先验；乘积会自然惩罚长路径。它不训练模型，而是影响边过滤与旋转/相似平均权重。源码：BatchInferenceStar.main L47–108。

10.3 旋转平均（式 11）

$$\min_{\{R\boxtimes\in SO(3)\}}\Sigma\,\rho(o\boxtimes\boxtimes\boxtimes\cdot d(R\boxtimes\boxtimes\boxtimes,R\boxtimes R\boxtimes\boxtimes))$$

R 为 3×3 旋转矩阵（实现以四元数参数化）；d 是 SO(3) 测地角；o 是重叠权重；ρ 为 Huber。右侧 R☒R☒☒ 是全局旋转诱导的相对旋转，应与局部预测 R☒☒☒ 一致。

为什么用测地距离+Huber：矩阵欧氏差忽略流形曲率；测地角有物理意义。平方损失会被错误 DG 边放大，Huber 在小误差保持二次、在大误差近似线性。优化固定规约方向，在四元数流形上求解。

极小例子：三条边角误差为 1°、2°、30°，第三条权重 0.1；加权后为 1、2、3 度，Huber 再削弱残余异常边，使前两条主导更新。

源码：rotation_averaging L140–240，其中 L199–211 建 residual，L213–230 配置流形与求解器。

10.4 星图尺度相似平均（式 12–13）

t☒☒☒=s☒R☒☒☒(c☒−c☒)
min$_{c,s}$Σ o☒☒ · d(R☒☒☒t☒☒−s☒(c☒−c☒))，s☒=1

形状：t,c∈☒^{3}；R∈☒$^{3\times3}$；s、o 为标量。每个星图共享一个 s☒，而不是每条边一个尺度。s☒=1 消除全局尺度规约自由度。

计算：先由旋转平均得到 R；最大生成树初始化 c、s；把每条有效星边转为三维方向/位移残差；Ceres 联合更新所有中心与星尺度；最后按尺度更新局部点/深度。

极小例子：星图 l 的两个局部平移长度为 2 和 4，而全局中心差候选为 1 和 2；统一 s☒=2 同时满足两边。逐边尺度也能拟合，但会把噪声吸收进不同尺度，失去星内一致性。

源码：similarity_averaging L223–311；尺度上下界 1e−5 到 1e5，默认最多 50 次迭代。

10.5 虚拟轨迹与总 BA 目标（式 14–15）

☒$_{l\to m}$☒=Π☒(R$_{lm}$☒(D☒☒☒(x)Π☒☒^{1}(x)−c$_{lm}$☒))
☒$_{l\to m}$☒=Π☒(R☒(R☒☒D☒☒☒(x)Π☒☒^{1}(x)+c☒)−c☒))
L=Σ$_{real}$Huber(||π(P,X)−x||☒)+Σ$_{virtual}$Arctan(||π(P,X☒)−v||☒)

形状：中心像素 x∈☒^{2}，光线 π☒^{1}(x)∈☒^{3}，深度为标量，X☒∈☒^{3}，每邻居虚拟观测 v∈☒^{2}。P、内参、真实/虚拟三维点进入同一个 Ceres 问题。

为什么允许画外/负深度：实体轨迹必须对应真正可见点，低重叠时正是约束缺失来源；虚拟轨迹不是物理对应，而是对前馈局部坐标关系的软编码，因此保留这些投影可约束相机相对关系。Arctan 比 Huber 更强地饱和，避免虚拟先验压过真实观测。

极小例子：若一条 SIFT 残差 0.5 px、一条虚拟残差 20 px，Huber 对前者近似二次；Arctan 对后者趋于饱和，仍提供方向但不会迫使相机为错误先验大幅移动。

梯度：训练阶段没有端到端反传；BA 梯度/雅可比只更新优化变量（相机、内参、点），不更新 π^{3}/VGGSfM 权重。源码：bundle_adjustment L206–300。

11. 核心算法 1：视图图初始化

衔接：把无序图像集合转成局部星图输入，位于所有深度/姿态推理之前。

输入/输出与 shape：输入 N 张不同 H☒×W☒×3 图像，检索每图 c 个邻居；DG 得到长度约 cN 的 score；输出稀疏边集 E 和每中心最多 25 个邻居（加中心共最多 T=26）。B 为 DG/星图 batch；N 为总图数；T 为星图帧数；C=3；H/W 为网络缩放后图像尺寸。

预处理：SALAD 检索、图像尺寸归一化、DG 两视图推理；按分数动态建连通图。mask 表示分数通过且端点属于不同分量。

训练/推理：论文发布的是推理管线；预训练模型冻结，代码使用 @torch.no_grad()。无新 loss 或反传。推理按两视图 batch → 星图收集顺序执行。

形状例子：N=1000、c=20 时候选 O(20000)，不是全连接约 50 万对；某中心有 40 个邻居时按 DG 取 25，π^{3} 输入 T=26。

```
# 自行编写的示意伪代码，不是作者原代码
candidates = SALAD.topk(images, k=c)
scores = DG(images[candidates])
E = empty_graph(N)
for delta in [0.8,0.7,0.6,0.5,0.4,0.3,0.2]:
E += {(i,j) for (i,j) in candidates
if scores[i,j] > delta and cc(i) != cc(j)}
if connected(E): break
E = largest_component(E)
stars = [top25_by_score(center_and_neighbors(i,E)) for i in range(N)]
```

源码：GluemapPipeline.run L84–122。注意论文描述的动态阈值细节分散在 dataset/star collection 模块，主入口只串联 twoview 与 collection。

12. 核心算法 2：局部星图前馈推理与共视估计

衔接：为每个星图输出局部外参、内参、深度/点、置信度、真实/虚拟轨迹；后续全局融合依赖这些相对几何。

shape：batch 中图像通常 [B=1,T,C,H,W]；外参 [1,T,4,4]；内参 [1,T,3,3]；深度 [1,T,H,W]（具体内部缩放由骨干决定）；track [B,Q,T,2]，Q 为查询点数；vis/conf [B,Q,T]。

预处理与 mask：星图中心置于第 0 帧；图像 resize 信息随 batch 保存以恢复原尺度；track 可见性/置信度成为后续 mask；往返深度误差生成共视分数。

训练：公开管线没有联合训练，π^3 与 tracker 权重加载后冻结；梯度不跨模型传播。

推理：依次调用 local inference、track inference、covisibility extraction；星图之间可并行。训练/推理差异主要是完全推理模式，无随机增强和 loss。

手工例子：B=1、T=4、H=W=224，若 Q=128，则轨迹张量约 [1,128,4,2]；每个查询在 4 帧有二维坐标与 4 个可见性值。中心到三个邻居的 VO 权重再进入全局图。

```
# 自行编写的示意伪代码
for star in stars_parallel:
pred = pi3(star.images) # pose/depth/intrinsics
track, vis, conf = vggsfm(star)
overlap = forward_backward_depth_check(pred)
emit(pred, track, vis, conf, overlap)
```

源码：BatchInferenceStar.main L47–108；局部与轨迹推理 L127–160。论文把输出写为姿态/焦距/深度/轨迹，代码还显式返回 pose_scores、虚拟点与 valid mask。

13. 核心算法 3：全局运动平均

衔接：把不同局部坐标系统一成全局粗重建，为虚拟轨迹和 BA 提供初值。

shape：每边相对旋转 3×3、平移 3；每图全局旋转 3×3、中心 3；每星图尺度 1；每物理相机内参向量依相机模型为 3 或更多参数。

预处理：过滤低置信/不一致边；同一物理相机焦距取中位数；旋转以 MST 或 pycolmap 初始化；相似平均以最大生成树初始化。

训练：无网络参数更新。Ceres 梯度只在流形/欧氏优化变量之间传递。

推理：先旋转后中心/尺度，旋转 Ceres 最多 200 次；相似平均默认最多 50 次；三角角度太小的星尺度被冻结；最后反代更新局部点与外参尺度。

手工例子：三张图形成两个星图，星 A 局部基线 [1,2]，星 B 局部基线 [2,4]；公共边表明 B 的尺度约为 A 的 2 倍。固定 s⊠=1 后求 s_B≈0.5，使两星映射到同一全局中心距离。

```
# 自行编写的示意伪代码
K = median_intrinsics(local_K)
R = rotation_average(relative_R, weight=overlap, robust='Huber')
c0, s0 = max_spanning_tree_init(relative_t, overlap)
c, s = similarity_average(R, relative_t, init=(c0,s0))
depth_global = {star: depth_local[star] / s[star]}
```

源码：GlobalGluer L22–76；旋转平均；相似平均。

14. 核心算法 4：轨迹吸附、虚拟轨迹与增强 BA

衔接：在全局粗姿态上把高精度局部特征、学习轨迹与前馈几何先验合并，输出最终 COLMAP 重建。

shape：每条轨迹含 K 个观测 (image_id,xy)，K 可不同；虚拟轨迹每中心约 Q⊠≈100，覆盖 T 个星图视图；相机参数、四元数/平移和三维点为可优化块。

预处理：前馈轨迹吸附到 1 px 内 SIFT 关键点；优先无条件加入 SIFT；只有跨越的某图像对当前匹配数 <512 时，才加入深度/虚拟轨迹；虚拟投影允许出画、负深度，成像平面附近被过滤。

训练：没有模型训练。BA 对实轨迹用 Huber，对虚拟轨迹用 Arctan；梯度更新相机、内参与三维点，模型冻结。

推理：代码先建 SIFT 数据库与三角化，再建立 mixed tracks，默认 refinement 迭代 2 轮；BA 内部默认上限 200 次。可用 track_mode 选择 S/P/V 组合。

手工例子：两个房间只有单一门框连接，真实轨迹只跨两帧，无法锁定远端尺度；中心图采样 100 条光线投到邻居，哪怕部分在画外，也给相机相对方向与尺度软约束。Arctan 让错误虚拟点饱和，门框 SIFT 仍主导局部精度。

```
# 自行编写的示意伪代码
sift = extract_and_match_sift()
prior = snap_to_sift(vggsfm_tracks, radius=1.0)
virtual = reproject_sampled_rays(local_pose, global_pose, global_depth)
tracks = all(sift)
tracks += undercovered(prior, threshold=512)
tracks += undercovered(virtual, threshold=512)
solve_BA(real_loss='Huber', virtual_loss='Arctan', allow_negative_depth=True)
```

源码：虚拟轨迹、吸附、refinement 串联 L262–337；A-BA L206–300；refinement 入口 L181–217。实现默认 track_mode='SPV'，与论文三类轨迹一致。

15. 30–60 分钟学习路线

- 0–8 分钟：看图 1、图 2，记住两类方法各自失败区域。
- 8–20 分钟：读 3.1–3.3，手写“DG 图→星图→R 平均→s 平均”四行数据流。
- 20–35 分钟：精读式（9）–（15），重点理解 VO 与虚拟轨迹不是同一件事：前者筛边/加权，后者补 BA 约束。
- 35–50 分钟：对照固定 commit 读 gluemap_impl.py、global_merger.py、augmented_bundle_adjustment.py。
- 50–60 分钟：比较 SMERF 与 LaMAR 表，回答“何时全前馈更好、何时传统更好、为何混合更稳”。

16. 代码学习任务

- 从 GluemapPipeline.run 画真实调用图，标出 GPU/CPU 数据迁移边界。
- 在 rotation_averaging 中跟踪 score 如何变成 Huber magnitude；将一条边 score 改为 0，预测 residual 数量变化。
- 为 相似平均 构造 3 相机/2 星图的最小单元测试，验证 s☒ 规约和低三角角度冻结。
- 阅读 A-BA 的负深度 residual，统计一次小样本中 real/virtual/negative-depth 的数量；不要先跑全 LaMAR。

17. 面试问题

问题 1：为什么把全局图拆成一阶星图不会丢掉远距离一致性？
答：前馈网络只负责局部高鲁棒几何；星图间通过共享节点/边形成重叠，远距离约束由旋转平均、相似平均和 BA 在全局图传播。因此局部网络不需要直接注意远端图像。

问题 2：虚拟轨迹允许负深度为何仍有意义，又为何不能替代真实轨迹？
答：它编码的是前馈模型给出的相对坐标关系，不是物理可见点；负深度投影仍对相机参数有可微约束。它可能携带模型偏差，所以用强饱和 Arctan，只作为软先验；SIFT/深度真实轨迹仍用更可信 Huber 主导几何精度。

18. 迁移实验想法

- VGGT + Depth Pro：用 VGGT 替换 π^3 输出局部 pose/depth，以 Depth Pro 的绝对尺度置信度为每星图 s☒ 加软先验；比较无尺度、单星尺度、绝对尺度三种相似平均。
- YOLO 驱动的动态过滤：在自动驾驶序列中用 YOLO mask 掉车辆/行人区域再算 VO 与虚拟轨迹，验证动态物体是否减少错误视图边和 A-BA 漂移。
- 多摄像头离线地图：把每个时间戳多相机组视作小星图，加入已知 rig 内参/外参硬约束；外部时序边仍由 DG+VO 过滤，测量大图半径下的全局漂移。
- Qwen2.5-VL / VLA Agent：把视图图连通性、VO、BA 残差统计编码成结构化“几何健康状态”，让 VLA 在主动采集时选择下一视角：优先补弱连通分量、低三角角度和尺度不确定区域，而非只看语义目标。