MoRe：运动感知前馈 4D 重建

新论文推荐 · CVPR 2026 Highlight · 2026-10-23

对应离线 ZIP：完整解压后双击 index.html。本 PDF 包含 13 项学习简报、创新对比、四个实现级算法、逐式数学解释和固定 commit 源码；完整原文与逐节译文在 ZIP 中。

1 基本信息

MoRe: Motion-aware Feed-forward 4D Reconstruction Transformer；CVPR 2026 Highlight；arXiv:2603.05078v2，15 页。标签：动态 4D 重建、单目视频、相机位姿、视频深度、流式 Transformer、运动分割。

证据分级：实验数字来自论文报告；代码位置来自固定 commit 的源码静态分析；本包没有下载权重或运行 GPU 推理，因此没有“已复现”结论。

2 个性化推荐理由

它补上 VGGT + Depth Pro + YOLO
流程最薄弱的一环：静态几何网络遇到行人、车辆或机械臂运动时，容易把对象运动误当成相机运动。可迁移三件事：用运动掩码约束 camera token；按帧 causal mask 做在线推理；第二组 camera token 做轻量全局校正。

3 一句话问题定义

在测试时没有真实运动掩码的前提下，从连续单目视频实时预测相机、深度、三维点和运动区域，并避免运动物体污染静态几何。

4 方法流程

- 输入 B×T×3×H×W，按 14×14 patch 编码并加入 camera/register token。
- 帧内注意力提取空间结构，全局注意力交换时间几何。
- 训练期运动掩码池化到 patch 网格，约束 camera token 注意力。
- 相机、深度、点图与运动头联合预测，多任务 loss 反传共享 backbone。
- 流式模式按帧使用 KV cache，同帧 token 全可见，未来帧不可见。
- 序列末复制 camera token 读取全局缓存，再输出校正位姿。

5 真正创新点与边界

模块	已有方法	瓶颈	MoRe 修改	证据
动态位姿	VGGT camera token 聚合所有 patch	移动物体污染位姿	运动掩码约束注意力	Sintel ATE 0.163→0.147
因果推理	逐 token 三角 mask	同帧 patch 不能完整交互	整帧分组 causal mask	AbsRel 0.277→0.254
长程一致性	纯在线只看历史	误差累积	复制 camera token 全局再聚合	去除后 ATE 0.155
基础网络	VGGT 交替 frame/global、多头预测	静态假设	沿用并动态微调	非本文原创

6 核心算法一：Attention Forcing

输入 $X \in R^{B\times T\times 3\times H\times W}$，运动标签 $M \in \{0,1\}^{B\times T\times H\times W}$，patch=14，P=(H/14)(W/14)。最后注意层相机查询权重 $A \in R^{(BT)\times h\times q\times P}$。

- 对 M 做 14×14 平均池化得到每 patch 运动比例。
- 保存末层 camera token 对 patch 的 softmax 权重。
- 池化分数扩展到 16 头和查询维，与 A 相乘求均值。
- 与其他任务 loss 相加，梯度回到 Q/K 与 backbone。

论文：a□=1−mean(M□)，L_attn=(1/P)Σmax(0,a□−C)α□；代码：mean(avgpool(M)×A)。两者不等价。

例：运动比例 [0.75,0]，注意力 [0.30,0.70]，代码项均值 0.1125，优化会压低运动 patch 注意力。

示意伪代码（非作者原代码）

```
score = avg_pool(mask, 14).flatten()
```

```
attn = camera_attention(last_layer)
loss_attn = mean(score * attn)
```

- compute_attn_loss
- Attention.forward

7 核心算法二：Grouped Causal Attention

每帧 P token，总长 L=T·P；Q/K/V$\in R^{B\times h\times L\times d}$。第 t 帧 query 范围 [tP,(t+1)P)，key 范围 [0,(t+1)P)，所以同帧互相可见、未来不可见。训练一次构造 q_ranges/k_ranges；推理每层缓存 K/V。

例：T=3、P=2。第二帧 query 2/3 可看 key 0…3，不能看 4/5；普通 token causal 会让 query 2 看不到同帧 token 3。

```
示意伪代码（非作者原代码）
for frame in video:
q,k,v = project(frame)
out = attention(q, concat(cache_k,k), concat(cache_v,v))
cache_k,cache_v = append(cache,k,v)
```

- 分组 ranges
- StreamAggregator

源码定义 window_size，但所读路径未见缓存切片到窗口长度的生效语句；窗口 5 是论文报告，不把它写成已运行验证。

8 核心算法三：联合多任务目标

camera$\in R^{B\times T\times 9}$；depth$\in R^{B\times T\times H\times W\times 1}$；world_points$\in R^{B\times T\times H\times W\times 3}$；motion$\in R^{B\times T\times H\times W\times 1}$。

L=w_mL_motion+w_aL_attn+w_cL_camera+w_dupL_dup+w_d(L_conf+L_reg+L_grad)_depth+w_p(...)_point

例：e^2=0.04、⊠=2、λ=0.1，则置信度项 2×0.04−0.1log2≈0.0107。

- 四个预测头
- MultitaskLoss

9 核心算法四：BA-like Refinement

训练为每帧追加 additional_camera_token，并以复制的相机位置重新读取全局 token，再由 CameraHead 解码。主 token B×(T·P)×C，复制 token B×T×C；两条路径均受相机 loss 监督。T=4、P=1005 时仅追加 4 个查询。

```
示意伪代码（非作者原代码）
stream_pose = camera_head(stream_tokens)
refined = attend(duplicate_camera_queries(T), all_cached_kv)
loss = L(stream_pose,gt) + L(camera_head(refined),gt)
```

- 复制 token
- 第二相机解码

10 实验与证据

- attention forcing：Sintel ATE 0.163→0.147。
- GCA：Sintel AbsRel 0.277→0.254，KITTI 0.079→0.072。
- BA-like：去除后 ATE 0.155，完整 0.147。
- A800/KITTI 512×144 报告 30.09 FPS。
- Co3Dv2 AUC@30 91.42，高于 VGGT 88.59。

11 局限与适用范围

- 依赖运动掩码质量；论文/代码损失有差异。
- 长程交互、极快非刚体运动、运动模糊、遮挡与外观突变仍困难。
- 适合连续单目动态视频；若有标定多相机、IMU 或激光雷达，应作为额外约束。

12 前置知识

- 针孔相机、SE(3)、ATE/RPE。
- Q/K/V、多头注意力与 causal mask。
- 深度、点图、光流和自运动光流。
- 置信度回归、BCE 与多任务 loss。
- KV cache 与 bundle adjustment。

13 30–60 分钟学习路线

- 0–8 分钟：看 pipeline，写出四个输出。
- 8–20 分钟：手算运动池化，对照论文/代码差异。
- 20–32 分钟：画 T=3、P=2 的 GCA mask。
- 32–45 分钟：从 vggt.py 跟四个 head，再看 loss.py。
- 45–60 分钟：设计迁移实验。

14 代码学习任务

- 同时实现论文式、当前源码式与 KL 三种 attention loss。
- 给 StreamAggregator 加真实 window=5 K/V 截断，验证显存随 T 稳定。
- 给四个 head、additional camera token、attn_weight 写 shape assertion。
- 用 2×3 帧合成输入验证同帧全可见、未来不可见。

15 面试问题

为何普通 causal 不适合视频 patch？展平顺序不是同帧真实时间；三角 mask 无意义地阻止同图 patch 交互。分组 causal 保留时间因果和空间完整性。

为何 attention forcing 测试时零开销？运动掩码只参与训练 loss，不作推理输入；偏好已写入参数。

16 迁移实验

VGGT + Depth Pro + YOLO

YOLO 轨迹与光流差生成弱运动掩码，在 VGGT camera token 加 MoRe loss；Depth Pro 提供单帧高频深度，MoRe 负责时间尺度与位姿。比较静态 VGGT、+mask head、+attention forcing、+GCA。

自动驾驶

每个时间戳的多摄像机为一个空间组，组内跨相机双向、组间只看过去。车辆/行人 mask 仅约束 ego-pose token，不删除动态对象。

Qwen2.5-VL / VLA Agent

把 pose/depth/motion 摘要编码成几何 memory token。SFT 学静态可通行区、动态速度和自运动；GRPO 奖励动作成功、避免碰撞和几何一致性。比较 RGB-only、+depth、+full 4D memory。